

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH  
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN  
KHOA CÔNG NGHỆ THÔNG TIN



# ĐỒ ÁN MÔN HỌC

# DỰ ĐOÁN GIÁ LAPTOP TẠI THỊ TRƯỜNG VIỆT NAM

Mã số sinh viên    Họ và tên

23120245

NGUYỄN QUANG DUY

23120258

LƯU TRỌNG HIẾU

23120260

VĂN ĐÌNH HIẾU

Giảng viên hướng dẫn TS. Bùi Tiến Lên

Th.S Lê Nhứt Nam

**Môn học**    Nhập môn Học Máy

Thành phố Hồ Chí Minh – 2026

## Danh sách hình vẽ

|    |                                                                                                                         |    |
|----|-------------------------------------------------------------------------------------------------------------------------|----|
| 1  | Cơ cấu tập dữ liệu hợp nhất theo nguồn. . . . .                                                                         | 5  |
| 2  | Phân bố giá gốc (trái, giới hạn từ P1 đến P99 để dễ quan sát) và giá sau biến đổi log (phải). . . . .                   | 8  |
| 3  | Phân bố giá theo nguồn, hiển thị trong khoảng P1–P99. . . . .                                                           | 9  |
| 4  | Giá trung vị theo nhóm RAM và nguồn dữ liệu. . . . .                                                                    | 10 |
| 5  | Tỷ lệ thiếu của các thuộc tính quan trọng theo nguồn. . . . .                                                           | 11 |
| 6  | So sánh RMSE giữa biến mục tiêu giá gốc và biến mục tiêu log theo từng mô hình. . . . .                                 | 14 |
| 7  | Learning curve RMSE của CatBoost sau tinh chỉnh (trái) và LightGBM baseline (phải). . . . .                             | 17 |
| 8  | Giá thực tế so với dự đoán (trái) và residual theo giá thực tế (phải) của CatBoost sau tinh chỉnh trên holdout. . . . . | 19 |
| 9  | Kiến trúc và luồng xử lý của ứng dụng Laptop Price Studio. . . . .                                                      | 22 |
| 10 | Màn hình chính của ứng dụng: nhập mô tả tự nhiên và hiển thị kết quả dự đoán. . . . .                                   | 25 |
| 11 | Chức năng so sánh và xếp hạng nhiều laptop theo giá rao và giá dự đoán. . . . .                                         | 25 |
| 12 | Biểu đồ khảo sát giá dự đoán theo RAM và dung lượng lưu trữ. . . . .                                                    | 26 |

## Danh sách bảng

|    |                                                                        |    |
|----|------------------------------------------------------------------------|----|
| 1  | Các nguồn dữ liệu và quy mô qua các giai đoạn chính . . . . .          | 5  |
| 2  | Các sự kiện làm sạch và kiểm tra chất lượng đáng chú ý . . . . .       | 7  |
| 3  | Thống kê mô tả của nhãn giá sau khi hợp nhất (triệu VND) . . . . .     | 8  |
| 4  | Quy mô dữ liệu qua bước chuẩn bị mô hình . . . . .                     | 12 |
| 5  | Cách chia dữ liệu dùng trong phát triển và đánh giá mô hình . . . . .  | 13 |
| 6  | Các bước tiền xử lý và feature engineering chính . . . . .             | 13 |
| 7  | So sánh các mô hình trong thí nghiệm modeling final . . . . .          | 14 |
| 8  | Kết quả baseline và tuned cho LightGBM/CatBoost trên holdout . . . . . | 16 |
| 9  | Metric holdout cuối cùng của các candidate . . . . .                   | 18 |
| 10 | Lỗi của CatBoost_tuned theo phân khúc giá . . . . .                    | 19 |
| 11 | Các mẫu có lỗi tuyệt đối lớn nhất . . . . .                            | 20 |
| 12 | Các thành phần chính của ứng dụng. . . . .                             | 23 |
| 13 | Phân công công việc trong nhóm . . . . .                               | 32 |

# Mục lục

|                                                    |           |
|----------------------------------------------------|-----------|
| Danh mục hình vẽ                                   | i         |
| Danh mục bảng biểu                                 | ii        |
| <b>1 Giới thiệu</b>                                | <b>1</b>  |
| 1.1 Phân tích vấn đề                               | 1         |
| 1.1.1 Dự đoán khoảng giá từ cấu hình               | 1         |
| 1.1.2 Đánh giá mức độ đáng mua                     | 2         |
| 1.2 Mục tiêu của đề án                             | 2         |
| 1.3 Tổng quan về phương pháp                       | 3         |
| 1.3.1 Thu thập và tiền xử lý dữ liệu               | 3         |
| 1.3.2 Xây dựng và biểu diễn đặc trưng              | 3         |
| 1.3.3 Lựa chọn và huấn luyện mô hình               | 3         |
| 1.3.4 Triển khai ứng dụng                          | 4         |
| <b>2 Thu thập và Phân tích Dữ liệu</b>             | <b>4</b>  |
| 2.1 Nguồn và phương pháp thu thập                  | 4         |
| 2.2 Tiền xử lý và làm sạch                         | 6         |
| 2.2.1 Làm sạch dữ liệu Chợ Tốt                     | 6         |
| 2.2.2 Làm sạch dữ liệu Websosanh                   | 6         |
| 2.3 Phân tích khám phá dữ liệu                     | 8         |
| 2.3.1 Phân bố nhãn và khác biệt giữa nguồn         | 8         |
| 2.3.2 Mối quan hệ giữa cấu hình và giá             | 9         |
| 2.3.3 Chất lượng dữ liệu và hàm ý mô hình hóa      | 10        |
| <b>3 Lựa chọn và Huấn luyện Mô hình</b>            | <b>11</b> |
| 3.1 Chuẩn bị dữ liệu cho mô hình                   | 12        |
| 3.1.1 Chia dữ liệu và nguyên tắc đánh giá          | 12        |
| 3.1.2 Biểu diễn đặc trưng và kiểm soát leakage     | 13        |
| 3.2 Lựa chọn và đặc điểm mô hình                   | 14        |
| 3.3 Cấu hình huấn luyện và tinh chỉnh siêu tham số | 15        |
| <b>4 Kết quả và Thảo luận</b>                      | <b>16</b> |
| 4.1 Kết quả thực nghiệm                            | 16        |
| 4.1.1 Learning curves và khả năng tổng quát hóa    | 16        |
| 4.1.2 Đánh giá trên tập holdout                    | 17        |
| 4.2 So sánh và thảo luận                           | 19        |
| 4.2.1 Sai số theo phân khúc giá                    | 19        |
| 4.2.2 Các trường hợp sai số điển hình              | 20        |

|          |                                                  |           |
|----------|--------------------------------------------------|-----------|
| <b>5</b> | <b>Xây dựng và Triển khai Ứng dụng</b>           | <b>21</b> |
| 5.1      | Kiến trúc hệ thống và tích hợp mô hình . . . . . | 21        |
| 5.2      | Giao diện và chức năng . . . . .                 | 24        |
| 5.3      | Triển khai local và hướng dẫn sử dụng . . . . .  | 26        |
| <b>6</b> | <b>Kết luận</b>                                  | <b>27</b> |
| 6.1      | Tóm tắt kết quả . . . . .                        | 27        |
| 6.2      | Hạn chế . . . . .                                | 28        |
| 6.3      | Hướng phát triển . . . . .                       | 29        |
|          | <b>Tài liệu tham khảo</b>                        | <b>31</b> |
| <b>A</b> | <b>Phụ lục</b>                                   | <b>32</b> |
| A.1      | Phân công công việc . . . . .                    | 32        |
| A.2      | Cấu trúc và tổ chức thư mục dự án . . . . .      | 32        |

# 1 Giới thiệu

## 1.1 Phân tích vấn đề

Laptop là thiết bị quan trọng đối với học sinh, sinh viên, nhân viên văn phòng và người dùng phổ thông tại Việt Nam. Tuy nhiên, việc xác định một mẫu laptop có mức giá hợp lý hay không vẫn tương đối khó đối với những người chưa có nhiều kinh nghiệm về phần cứng và thị trường máy tính.

Giá laptop phụ thuộc vào nhiều yếu tố như thương hiệu, dòng sản phẩm, bộ vi xử lý, card đồ họa, dung lượng RAM, dung lượng lưu trữ, màn hình và hệ điều hành. Ngay cả các phiên bản thuộc cùng một dòng sản phẩm nhưng khác RAM hoặc dung lượng lưu trữ cũng có thể có mức giá chênh lệch đáng kể. Vì vậy, người dùng khó đánh giá mức giá do cửa hàng hoặc người bán cung cấp có phù hợp với mặt bằng thị trường hay không.

Trong thực tế, người mua thường phải tìm kiếm và so sánh nhiều sản phẩm trên các trang bán lẻ khác nhau. Quá trình này tốn thời gian và dễ dẫn đến đánh giá thiếu chính xác, đặc biệt khi người dùng chỉ tập trung vào một số thông số dễ nhận biết như RAM hoặc dung lượng lưu trữ mà chưa xem xét đầy đủ CPU, GPU, thương hiệu và dòng sản phẩm.

Bên cạnh đó, các hệ thống được xây dựng từ dữ liệu quốc tế có thể không phản ánh chính xác bối cảnh Việt Nam do sự khác biệt về nguồn hàng, chính sách phân phối, thuế và mức độ phổ biến của từng thương hiệu. Vì vậy, nhóm xây dựng một hệ thống học máy dự đoán giá niêm yết tham chiếu từ hai nguồn dữ liệu Chợ Tốt và Websosanh. Phạm vi này không đồng nghĩa với việc mô hình đã ước lượng được một “giá trị thị trường” duy nhất cho mọi laptop tại Việt Nam.

Hệ thống được thiết kế với hai cơ chế định giá chính.

### 1.1.1 Dự đoán khoảng giá từ cấu hình

Ở cơ chế thứ nhất, người dùng cung cấp mô tả về chiếc laptop cần định giá, bao gồm một số thông tin như thương hiệu, dòng máy, CPU, GPU, RAM, dung lượng lưu trữ và màn hình.

Hệ thống trả về một giá trị dự đoán đi kèm khoảng giá tham khảo. Khoảng này được tạo bằng quy tắc thực nghiệm dựa trên RMSE quan sát và mức độ thiếu thông tin; đây không phải khoảng tin cậy hay *prediction interval* có mức bao phủ xác suất xác định. Khi người dùng cung cấp đầy đủ hơn các thuộc tính quan trọng, thành phần độ rộng do thiếu thông tin được giảm; độ rộng cuối cùng vẫn phụ thuộc vào sai số quan sát của phân khúc giá tương ứng.

Ngoài kết quả chính, ứng dụng tự động tạo các biến thể cấu hình bằng cách thay đổi RAM và dung lượng lưu trữ, trong khi giữ nguyên các thuộc tính còn lại. Ví dụ, hệ thống có thể tính lại dự đoán cho các mức lưu trữ 256 GB, 512 GB, 1 TB và 2 TB. Đây

là khảo sát phản ứng của mô hình, không phải ước lượng nhân quả về chi phí nâng cấp. Một số tổ hợp sinh tự động có thể hiếm gặp, không tương thích hoặc nằm ngoài miền dữ liệu huấn luyện, nên chỉ được dùng để tham khảo xu hướng dự đoán.

### 1.1.2 Đánh giá mức độ đáng mua

Ở cơ chế thứ hai, người dùng cung cấp cấu hình laptop cùng với mức giá đang được chào bán. Hệ thống dự đoán mức giá niêm yết tham chiếu theo dữ liệu huấn luyện và so sánh với giá do người dùng nhập vào.

Mức chênh lệch tương đối được xác định theo công thức:

$$\Delta = \frac{P_{\text{user}} - P_{\text{pred}}}{P_{\text{pred}}} \times 100\%, \quad (1)$$

trong đó  $P_{\text{user}}$  là giá do người dùng cung cấp và  $P_{\text{pred}}$  là giá do mô hình dự đoán.

Nếu giá bán cao hơn đáng kể so với mức dự đoán, hệ thống gắn nhãn mô tả giá rao cao so với mức mô hình ước lượng. Ngược lại, giá bán gần với hoặc thấp hơn giá dự đoán được gắn nhãn thuận lợi hơn. Các nhãn này chưa được đánh giá như một bài toán ra quyết định độc lập và không tự thân chứng minh sản phẩm “đáng mua”.

Kết quả này chủ yếu dựa trên cấu hình và mặt bằng giá trong dữ liệu. Các yếu tố như chất lượng hoàn thiện, thời lượng pin, tình trạng sản phẩm, chính sách bảo hành và uy tín người bán chưa được phản ánh đầy đủ. Vì vậy, hệ thống đóng vai trò hỗ trợ thay vì thay thế hoàn toàn quyết định của người dùng.

## 1.2 Mục tiêu của đề án

Mục tiêu tổng quát của đề án là xây dựng và triển khai một hệ thống học máy dự đoán giá niêm yết tham chiếu trong phạm vi dữ liệu thu thập từ Chợ Tốt và Websosanh, đồng thời cung cấp các chức năng phân tích dễ hiểu cho người dùng phổ thông.

Các mục tiêu cụ thể bao gồm:

- Thu thập dữ liệu laptop từ nhiều nguồn bán hàng tại Việt Nam, bảo đảm sự đa dạng về thương hiệu, cấu hình và phân khúc giá.
- Chuẩn hóa, làm sạch và chuyển dữ liệu từ nhiều nguồn về một cấu trúc thống nhất.
- Trích xuất, làm giàu và biểu diễn các đặc trưng có ảnh hưởng đến giá laptop.
- Xây dựng và so sánh nhiều mô hình hồi quy với các phương pháp mã hóa đặc trưng khác nhau.
- Lựa chọn, tinh chỉnh và phân tích sai số của các ứng viên có metric tốt trong quy trình thử nghiệm hiện tại.

- Xây dựng ứng dụng web cho phép dự đoán khoảng giá, mô phỏng thay đổi RAM và dung lượng lưu trữ.
- So sánh giá do người dùng cung cấp với giá dự đoán để hỗ trợ đánh giá mức độ đáng mua.
- Đóng gói mô hình và tích hợp vào hệ thống thông qua API.

Bên cạnh các metric dự đoán, đề án còn xem xét khoảng cách train-validation, phân tích sai số và khả năng tích hợp mô hình vào ứng dụng minh họa.

## 1.3 Tổng quan về phương pháp

Quy trình thực hiện đề án gồm các giai đoạn chính: thu thập dữ liệu, tiền xử lý, xây dựng đặc trưng, huấn luyện mô hình, đánh giá và triển khai ứng dụng.

### 1.3.1 Thu thập và tiền xử lý dữ liệu

Dữ liệu được thu thập từ nhiều nguồn bán laptop tại Việt Nam nhằm bao phủ nhiều thương hiệu, dòng máy, cấu hình và phân khúc giá. Do mỗi nguồn có cách đặt tên và mô tả sản phẩm khác nhau, dữ liệu cần được chuẩn hóa trước khi sử dụng.

Các bước tiền xử lý gồm loại bỏ bản ghi trùng lặp, xử lý giá trị thiếu, thống nhất đơn vị đo, chuẩn hóa tên thương hiệu và linh kiện, trích xuất thông số từ tên sản phẩm, đồng thời loại bỏ các bản ghi không phù hợp hoặc có mức giá bất thường.

### 1.3.2 Xây dựng và biểu diễn đặc trưng

Từ dữ liệu đã làm sạch, nhóm giữ lại các thuộc tính có ý nghĩa đối với bài toán và tạo thêm các đặc trưng giúp mô tả tốt hơn cấu hình laptop. Các biến phân loại được thử nghiệm với nhiều phương pháp mã hóa khác nhau để đánh giá cách biểu diễn phù hợp nhất.

Quá trình thí nghiệm tập trung vào ảnh hưởng của từng nhóm đặc trưng, phương pháp mã hóa và việc bổ sung hoặc loại bỏ thuộc tính đối với sai số dự đoán.

### 1.3.3 Lựa chọn và huấn luyện mô hình

Nhóm thử nghiệm các mô hình hồi quy từ tuyến tính đến phi tuyến, bao gồm:

- Linear Regression, Ridge, Lasso và Elastic Net;
- Random Forest và Extra Trees;
- LightGBM và CatBoost.



Các mô hình được huấn luyện và đánh giá trên cùng cách chia dữ liệu và cùng bộ chỉ số. Sự nhất quán này hỗ trợ so sánh, nhưng không loại bỏ preprocessing leakage. LightGBM và CatBoost được tinh chỉnh bằng `RandomizedSearchCV` trên tập phát triển.

Hiệu năng các phiên bản đánh giá được mô tả chủ yếu bằng MAE, RMSE và  $R^2$ . Ngoài kết quả tổng thể, nhóm phân tích sai số theo phân khúc giá và kiểm tra một số trường hợp sai số lớn.

### 1.3.4 Triển khai ứng dụng

CatBoost tuned được huấn luyện lại và tích hợp vào ứng dụng thông qua API. Backend dùng encoder để tạo đúng schema 86 đặc trưng và cùng quy ước `condition_score` với preprocessing huấn luyện.

Ứng dụng cung cấp hai chức năng chính:

- Dự đoán khoảng giá và tự động sinh các phương án thay đổi RAM hoặc dung lượng lưu trữ;
- So sánh giá rao với giá dự đoán và gắn nhãn theo quy tắc tham khảo chưa được validation như một quyết định mua.

Pipeline tổng thể của hệ thống được tóm tắt như sau:

Thu thập dữ liệu → Tiền xử lý và chuẩn hóa  
→ Xây dựng đặc trưng → Huấn luyện mô hình (2)  
→ Tinh chỉnh và phân tích sai số → Triển khai ứng dụng.

## 2 Thu thập và Phân tích Dữ liệu

### 2.1 Nguồn và phương pháp thu thập

Dữ liệu được xây dựng từ hai nguồn web bổ sung cho nhau. Nguồn *Chợ Tốt* là các tin rao laptop, phản ánh mạnh thị trường máy đã qua sử dụng; mỗi bản ghi có đường dẫn tin, tiêu đề, giá do người bán đăng và các thông số người bán khai báo. Nguồn *Websosanh* là catalog sản phẩm/giá từ nhiều cửa hàng trực tuyến, phản ánh chủ yếu thị trường laptop mới. Không sử dụng API; dữ liệu được thu thập theo hình thức trích xuất web và lưu ở dạng CSV để có thể kiểm tra lại từng lần chạy pipeline.


Quy trình xử lý dữ liệu được cài đặt bằng Python trong notebook, với `pandas` và `numpy` cho thao tác dữ liệu, biểu thức chính quy để phân tích chuỗi thông số, và `matplotlib/seaborn` cho trực quan hóa. Mỗi nguồn được lưu riêng ở trạng thái thô, trạng thái đã làm sạch và trạng thái sẵn sàng mô hình hóa; kèm theo đó là bảng liệt kê

vấn đề, báo cáo tóm tắt và nhật ký JSON. Cách tổ chức này cho phép đối chiếu lại một giá trị đã biến đổi với bản ghi gốc và chạy lặp lại toàn bộ pipeline.

Bảng 1: Các nguồn dữ liệu và quy mô qua các giai đoạn chính

| Nguồn     | Đặc điểm và trường thông tin chính                                                                 | Dữ liệu thô | Dữ liệu hợp lệ |
|-----------|----------------------------------------------------------------------------------------------------|-------------|----------------|
| Chợ Tốt   | Tin rao; URL, tiêu đề, giá, hãng, dòng máy, tình trạng, bảo hành, màn hình, CPU, RAM, GPU, lưu trữ | 5.866       | 5.698          |
| Websosanh | Catalog sản phẩm; thông số kỹ thuật và tối đa ba mức giá/cửa hàng cho một sản phẩm                 | 4.384       | 4.382          |
| Tổng      | Tập dữ liệu chuẩn hóa phục vụ EDA và mô hình hóa                                                   | 10.250      | 10.080         |

Với Chợ Tốt, giá ban đầu là chuỗi như 9.990.000 đ; các thuộc tính kỹ thuật cũng thường ở dạng văn bản bán cấu trúc. Với Websosanh, ba cột giá chỉ là các vị trí giá thập được cùng sản phẩm, không được xem là ba cửa hàng cố định. Do đó, chúng được chuẩn hóa thành giá trị số, kiểm tra độc lập, rồi tổng hợp bằng trung vị để tạo giá tham chiếu. Hình 1 cho thấy hai nguồn đóng góp tương đối cân bằng, nhưng khác biệt về bản chất dữ liệu cần được giữ lại trong quá trình kiểm tra và đánh giá mô hình.



Hình 1: Cơ cấu tập dữ liệu hợp nhất theo nguồn.

## 2.2 Tiền xử lý và làm sạch

Pipeline được tách riêng theo nguồn vì cấu trúc và rủi ro chất lượng dữ liệu khác nhau, sau đó mới đưa về một schema chung. Các trường đích cuối cùng là `target_price` và `log_target_price`; các trường mô tả cấu hình cốt lõi gồm hãng/dòng máy, CPU, GPU, RAM (GB), lưu trữ (GB), kích thước màn hình và các cờ thiếu/bất thường.

Trình tự xử lý chung gồm năm bước: (1) đọc dữ liệu CSV và kiểm tra số dòng, kiểu dữ liệu, miền giá trị và khóa định danh; (2) chuẩn hóa văn bản, đơn vị đo và các giá trị thiếu; (3) trích xuất thông số định lượng/tạo các nhóm cấu hình; (4) kiểm tra trùng lặp, ngoại lệ và tính nhất quán giữa các trường; (5) lưu dữ liệu đã làm sạch cùng các cờ audit, rồi ánh xạ hai nguồn sang schema chuẩn để hợp nhất. Cờ audit được tách khỏi biến mô hình hóa nếu nó được sinh ra từ giá hoặc chỉ có ý nghĩa ở một nguồn.

### 2.2.1 Làm sạch dữ liệu Chợ Tốt

Đầu tiên, văn bản được chuẩn hóa về khoảng trắng, chữ hoa/thường và các biểu diễn đơn vị (chẳng hạn 8 GB, 8GB được đưa về cùng dạng). Giá được tách từ chuỗi tiền tệ sang VND; hãng, dòng máy và thông số được đối chiếu giữa các trường có cấu trúc và tiêu đề. Các biểu thức mẫu được dùng để trích xuất RAM, dung lượng lưu trữ, kích thước màn hình, hãng/phân khúc CPU và phân khúc GPU. Khi một thông số trong trường riêng không hợp lệ nhưng có thể nhận diện đáng tin cậy từ tiêu đề, giá trị suy luận được lưu tách biệt; nếu không, biến số được để thiếu và gắn cờ. Các danh mục quá hiếm được gom vào nhóm *Other* để giảm phân mảnh.

Dữ liệu Chợ Tốt giữ nguyên 5.866 dòng sau làm sạch cơ bản để phục vụ audit, tăng từ 15 lên 60 cột bao gồm đặc trưng dẫn xuất và cờ kiểm tra. Không có dòng trùng hoàn toàn hoặc URL trùng. Khi tạo tập hợp nhất, 168 dòng không đạt điều kiện về biến mục tiêu bị loại: một dòng thiếu giá được đưa vào vùng cách ly và 167 dòng có giá ngoài miền cuối cùng không được đưa vào tập mô hình. Vì vậy, số bản ghi Chợ Tốt hợp lệ ở Bảng 1 là 5.698. Các cảnh báo ở cấp thuộc tính như RAM, màn hình hoặc cấu hình/sửa chữa chỉ được gắn cờ, không làm mất cả bản ghi; với thông số không thể tin cậy, giá trị số được đặt thiếu để mô hình không học từ một phép tách sai.

### 2.2.2 Làm sạch dữ liệu Websosanh

Đối với mỗi sản phẩm, ba giá quan sát được trước hết chuyển sang số VND và đếm số giá khả dụng. Từng ô giá được kiểm tra trong miền 3–200 triệu VND. Bốn ô giá ngoài miền bị làm rỗng; tiếp theo, một giá nhỏ hơn 0,5 lần hoặc lớn hơn 2 lần trung vị của các giá hợp lệ cùng sản phẩm được xem là ngoại lệ tương đối. Bước này làm rỗng thêm 53 ô, nhưng không làm mất toàn bộ giá của sản phẩm nào. Từ các giá sạch, pipeline tạo giá nhỏ nhất, lớn nhất, trung vị, số nguồn giá hợp lệ và phần trăm chênh lệch giá. Giá tham chiếu được chọn là trung vị các giá sạch còn lại. Với đủ ba quan sát, trung vị có thể hạn

chế ảnh hưởng của một giá cực trị; nhưng với hai quan sát, trung vị bằng trung bình của hai giá, còn với một quan sát thì không có khả năng kháng ngoại lệ. Do đó, lựa chọn này chỉ có độ bền hạn chế và không thay thế cho việc xác minh nguồn giá.

Các giá trị màn hình không hợp lý được xử lý ở cấp trường (85 giá trị), tương tự với hai giá trị RAM bất thường. Các bản ghi lặp hoàn toàn không xuất hiện. Trong tập Websosanh hợp lệ, 2.514 dòng mang cờ `is_soft_duplicate_spec`; cờ này được tính trong pipeline riêng của Websosanh theo `spec_key` gồm hãng, CPU, RAM, lưu trữ và màn hình. Các dòng được giữ ở tầng làm sạch vì có thể là nhiều mức giá/cửa hàng hợp lệ của cùng cấu hình.

Bảng 2: Các sự kiện làm sạch và kiểm tra chất lượng đáng chú ý

| Nguồn     | Hạng mục                 | Số lượng   | Cách xử lý                                 |
|-----------|--------------------------|------------|--------------------------------------------|
| Chợ Tốt   | Giá thiếu                | 1 dòng     | Cách ly khỏi tập mô hình                   |
| Chợ Tốt   | Giá ngoài miền cuối cùng | 167        | Giữ trong dữ liệu audit; loại khi hợp nhất |
| Chợ Tốt   | Màn hình thiếu           | 1.037      | Cờ thiếu; giữ thông tin còn lại            |
| Chợ Tốt   | GPU thiếu                | 1.421      | Cờ thiếu/nhãn <i>Missing</i>               |
| Websosanh | Giá ngoài miền           | 4 ô        | Làm rộng ở cấp ô giá                       |
| Websosanh | Giá lệch tương đối       | 53 ô       | Làm rộng ở cấp ô giá                       |
| Websosanh | Cảnh báo spread giá      | 583 dòng   | Chỉ dùng để audit, không làm đặc trưng     |
| Websosanh | Lặp mềm cấu hình         | 2.514 dòng | Giữ lại và gắn cờ                          |

Giá trị thiếu không được điền đồng loạt vì nguyên nhân thiếu khác nhau giữa nguồn và thuộc tính. Với biến phân loại, giá trị thiếu được biểu diễn tường minh bằng *Unknown/Missing*; với biến số, giá trị thiếu và cờ thiếu được giữ trong dữ liệu đã làm sạch. Trong lần chạy hiện tại, một số bước như xây dựng schema mã hóa và gom nhóm danh mục được thực hiện trước khi chia dữ liệu, trong khi các phép biến đổi cần ước lượng như chuẩn hóa biến số được *fit* trên phần huấn luyện. Hạn chế này và nguy cơ *preprocessing leakage* được trình bày chi tiết ở chương mô hình hóa.


Cuối cùng, hai nguồn được ánh xạ về cùng tên cột và cùng đơn vị, sau đó nối theo hàng. Các cột định danh/metadata (URL, tiêu đề, khóa cấu hình, mã dòng) được

giữ cho truy vết nhưng không dùng làm biến đầu vào. Các biến tạo trực tiếp từ giá như `price_spread_clean_pct` và các cờ spread cũng bị loại khỏi bộ đặc trưng cơ sở để tránh leakage.

## 2.3 Phân tích khám phá dữ liệu

### 2.3.1 Phân bố nhãn và khác biệt giữa nguồn

Phân bố giá có đuôi phải rõ rệt (skewness 2,75; tỷ lệ phân vị 95% trên trung vị là 3,37). Vì vậy, ngoài giá gốc, nhóm giữ biến  $\log(\text{price})$  để so sánh trong giai đoạn mô hình hóa. Bảng 3 cho thấy sự khác biệt lớn giữa hai nguồn: Chợ Tốt tập trung ở phân khúc đã qua sử dụng, trong khi Websosanh có mức giá và độ phân tán cao hơn. Đây là khác biệt thị trường thực tế, không phải lỗi cần xóa. Lần chạy hiện tại đánh giá tập hợp nhất và phân tầng phép chia theo khoảng giá.




Hình 2: Phân bố giá gốc (trái, giới hạn từ P1 đến P99 để dễ quan sát) và giá sau biến đổi log (phải).

Hình 2 cho thấy phần lớn quan sát tập trung ở vùng giá thấp–trung bình và giảm dần về phía giá cao. Biến đổi log nén phần đuôi phải, nhờ đó phân bố phù hợp hơn để thử nghiệm các mô hình nhảy với độ lệch của biến mục tiêu.

Bảng 3: Thống kê mô tả của nhãn giá sau khi hợp nhất (triệu VND)

| Nguồn     | $n$   | Trung bình | Trung vị | Q1    | Q3    | P95   |
|-----------|-------|------------|----------|-------|-------|-------|
| Chợ Tốt   | 5.698 | 10,08      | 7,89     | 4,70  | 13,00 | 25,99 |
| Websosanh | 4.382 | 26,04      | 21,20    | 15,20 | 30,99 | 57,59 |




Hình 3: Phân bố giá theo nguồn, hiển thị trong khoảng P1–P99.

Hình 3 trực quan hóa chênh lệch về trung vị và khoảng tứ phân vị giữa hai nguồn, nhất quán với Bảng 3. Các mức giá thấp nhất của Chợ Tốt quanh 1 triệu VND có thể bao gồm máy lỗi, máy thiếu linh kiện hoặc tin rao đặc biệt; các giá cao của Websosanh (tối đa 179,4 triệu VND) thường thuộc phân khúc cao cấp. Các điểm này được giữ khi còn hợp lý về miền giá, vì chúng là một phần của bài toán dự đoán, nhưng phân phối lệch là lý do cần kiểm tra cả mục tiêu log và các chỉ số sai số theo phân khúc.

### 2.3.2 Mỗi quan hệ giữa cấu hình và giá

Các biến số cấu hình có quan hệ dương với giá, mạnh nhất là lưu trữ và RAM. Tương quan Pearson với giá gốc lần lượt là 0,680 và 0,676; kích thước màn hình chỉ đạt 0,175. Do Pearson chỉ đo mức liên hệ tuyến tính và nhạy với quan sát cực trị, các hệ số trên thang giá gốc cần được diễn giải thận trọng. Khi tính lại trên  $\log(\text{price})$ , tương quan với RAM và lưu trữ đều tăng nhẹ, cho thấy mối liên hệ trong mẫu trở nên tuyến tính hơn trên thang log. Riêng kết quả này chưa đủ để kết luận quan hệ có dạng nhân hoặc mang tính nhân quả; nó chỉ hỗ trợ việc giữ song song hai target để so sánh ở Chương 3. Nhìn chung, dù tính trên thang nào, RAM và lưu trữ vẫn là tín hiệu quan trọng trong các biến số, nhưng không đủ để định giá độc lập vì cùng một mức RAM/lưu trữ vẫn có thể thuộc nhiều phân khúc CPU, GPU và thương hiệu khác nhau.




Hình 4: Giá trung vị theo nhóm RAM và nguồn dữ liệu.

Hình 4 cho thấy giá trung vị nhìn chung tăng theo mức RAM trong từng nguồn, nhưng mức giá tuyệt đối vẫn khác biệt đáng kể giữa hai nguồn. Trong dữ liệu Websosanh, trung vị giá tăng từ khoảng 12,17 triệu VND ở nhóm RAM không quá 4GB lên 25,00 triệu ở 16GB và 84,52 triệu ở 64GB. Theo lưu trữ, trung vị tăng từ 14,99 triệu VND ở nhóm không quá 256GB lên 30,88 triệu ở 1TB và 56,50 triệu ở 2TB. Phân tích theo nhóm cũng cho thấy giá có xu hướng khác biệt giữa các phân khúc CPU, GPU và thương hiệu; các nhóm có ít quan sát được gom nhóm trước khi mã hóa để tránh kết luận hay học quá mức từ một vài cấu hình hiếm.

### 2.3.3 Chất lượng dữ liệu và hàm ý mô hình hóa

Thiếu dữ liệu có cấu trúc theo nguồn. Trên toàn bộ 5.866 dòng Chợ Tốt ở tầng làm sạch và audit, màn hình thiếu khoảng 17,7% (1.037/5.866) và GPU thiếu khoảng 24,2% (1.421/5.866). Hình 5 được tạo từ tập hợp nhất gồm 5.698 dòng Chợ Tốt hợp lệ; trên tầng này, số thiếu tương ứng là 892 dòng màn hình (15,7%) và 1.307 dòng GPU (22,9%). Ở Websosanh, các tỷ lệ trên tập hợp nhất lần lượt khoảng 2,2% và 4,7%. Vì thế, cờ thiếu được giữ như một tín hiệu về chất lượng tin rao thay vì chỉ thay thế bằng một giá trị trung bình. Các thuộc tính như xuất xứ, bảo hành và dòng máy không có độ phủ đồng đều giữa hai nguồn, nên được kiểm soát khi chọn biến.



Hình 5: Tỷ lệ thiếu của các thuộc tính quan trọng theo nguồn.

Hình 5 xác nhận dữ liệu thiếu không phân bố đồng đều theo nguồn. Các trường chỉ được thu thập ở một nguồn, như tình trạng, bảo hành hoặc dòng máy, không được diễn giải là “thiếu ngẫu nhiên” và cần được xử lý thận trọng khi so sánh mô hình giữa hai nguồn.

Sau hợp nhất, phép kiểm tra trên `merged_spec_key` ghi nhận 6.882 dòng thuộc 1.530 khóa xuất hiện nhiều hơn một lần; không có khóa lặp chéo giữa hai nguồn. Con số này khác 2.514 dòng mang cờ `is_soft_duplicate_spec`, vì cờ được tạo trước khi hợp nhất bằng khóa riêng của Websosanh. Bước feature engineering cuối loại 2.514 dòng theo cờ nguồn này, chứ không loại toàn bộ 6.882 dòng lặp theo khóa hợp nhất. Vì vậy, bước lọc hiện tại không bảo đảm một cấu hình hợp nhất chỉ xuất hiện ở một fold. Bộ đặc trưng cơ sở gồm 26 biến cấu hình, danh mục đã gom nhóm và cờ chất lượng; phép kiểm tra tự động không phát hiện biến cấm hay biến dẫn xuất từ nhãn trong bộ này.

Tóm lại, tập dữ liệu sau xử lý giữ được 10.080 quan sát có giá hợp lệ và các cờ về thiếu dữ liệu, ngoại lệ và độ tin cậy. Các cờ hỗ trợ audit, nhưng không tự bảo đảm đã kiểm soát hết trùng lặp hay leakage; khóa lặp không thống nhất và preprocessing trước khi chia dữ liệu vẫn là hai hạn chế của lần chạy hiện tại.

### 3 Lựa chọn và Huấn luyện Mô hình

Sau bước làm sạch và xây dựng đặc trưng, tập dữ liệu dùng cho mô hình gồm 7.296 mẫu. Từ 10.080 quan sát hợp lệ sau hợp nhất, pipeline feature engineering loại 2.514 dòng mang cờ `is_soft_duplicate_spec` được tạo trong pipeline Websosanh. Cờ này không đồng nhất với phép lặp trên `merged_spec_key`: tập hợp nhất có 6.882 dòng thuộc 1.530



khóa hợp nhất xuất hiện nhiều lần. Do đó, việc loại 2.514 dòng làm mất một phần quan sát Websosanh phổ biến nhưng không bảo đảm mọi khóa hợp nhất được tách giữa train và validation. Nhóm giữ nguyên quy tắc này để bảo toàn tập dữ liệu và kết quả thực nghiệm đã chốt; giới hạn được ghi nhận thay vì thay đổi sang group split. Sau khi tạo và mã hóa đặc trưng, 270 dòng trùng hoàn toàn còn lại cũng được loại. Sau toàn bộ bước xây dựng và mã hóa đặc trưng, bộ đặc trưng chuẩn của tập đã xử lý gồm 86 biến. Bài toán được biểu diễn là hồi quy có giám sát với biến mục tiêu chính `target_price`, tính theo triệu VND. Biến `log_target_price` vẫn được giữ để kiểm tra ảnh hưởng của phân bố lệch phải đã quan sát ở Chương 2.

Bảng 4: Quy mô dữ liệu qua bước chuẩn bị mô hình

| Giai đoạn                                         | Số mẫu bị loại | Số mẫu còn lại |
|---------------------------------------------------|----------------|----------------|
| Sau hợp nhất và làm sạch                          | —              | 10.080         |
| Loại dòng mang cờ lặp mềm Websosanh               | 2.514          | 7.566          |
| Loại dòng trùng hoàn toàn sau feature engineering | 270            | 7.296          |

### 3.1 Chuẩn bị dữ liệu cho mô hình

#### 3.1.1 Chia dữ liệu và nguyên tắc đánh giá

Tập dữ liệu được chia cố định theo tỷ lệ 80/20, sử dụng `random_state=42` để bảo đảm khả năng tái lập. Hai mươi phần trăm dữ liệu được giữ lại làm tập holdout đánh giá (*evaluation holdout*), sau đây gọi là *tập holdout*; tập này không được dùng để *fit* point model hoặc tìm siêu tham số. Phần 80% còn lại, sau đây gọi là *tập phát triển*, được dùng cho huấn luyện, đánh giá chéo và tinh chỉnh. Do phân phối giá lệch phải, phép chia chỉ được phân tầng theo năm nhóm phân vị giá, không phân tầng theo nguồn. Holdout sau đó được dùng để báo cáo nhiều ứng viên và để tạo RMSE/ngưỡng phân khúc cho quy tắc khoảng giá của ứng dụng. Vì vậy, tập này không còn là tập test độc lập cho toàn bộ hệ thống và không nên được dùng cho thêm bất kỳ quyết định nào.

Không tách riêng một validation set cố định. Vì `StratifiedKFold` không áp dụng trực tiếp cho biến mục tiêu liên tục, giá được tạm chia thành năm nhóm phân vị *chỉ để tạo chỉ mục các fold*; mô hình vẫn học trên giá liên tục ban đầu và các nhóm này không phải biến đầu vào. Trên tập phát triển, *Stratified KFold* 5-fold tạo lần lượt năm tập validation. Mỗi vòng dùng xấp xỉ 4.669 mẫu để huấn luyện và 1.167 mẫu để validation; kết quả trung bình và độ lệch chuẩn qua năm fold là cơ sở đánh giá độ ổn định. Cách làm này tận dụng tốt dữ liệu huấn luyện và giảm phụ thuộc vào một lần chia ngẫu nhiên.

Bảng 5: Cách chia dữ liệu dùng trong phát triển và đánh giá mô hình

| Tập dữ liệu           | Số mẫu | Tỷ lệ  | Vai trò                                    |
|-----------------------|--------|--------|--------------------------------------------|
| Tập phát triển        | 5836   | 80.0%  | Huấn luyện, tinh chỉnh và Stratified KFold |
| Evaluation holdout    | 1460   | 20.0%  | Báo cáo đánh giá sau lựa chọn bằng CV      |
| Huấn luyện triển khai | 7296   | 100.0% | Huấn luyện lại mô hình đã chọn             |

### 3.1.2 Biểu diễn đặc trưng và kiểm soát leakage

Các biến số gồm RAM, dung lượng lưu trữ, kích thước màn hình và các đặc trưng tương tác giữa RAM–lưu trữ. Các biến phân loại như hãng, dòng máy, CPU, GPU, loại ổ cứng và bảo hành được làm sạch, gom nhóm hiếm khi cần thiết, rồi mã hóa one-hot hoặc ordinal tùy thuộc bản chất có/không có thứ tự. Các cờ *missing/no-info* được giữ để biểu diễn mức độ đầy đủ của thông tin.

Các biến định danh, biến mục tiêu, biến dẫn xuất trực tiếp từ giá và các cột audit có nguy cơ leakage đã bị loại khỏi ma trận đầu vào. Bộ đặc trưng sau feature engineering gồm 86 biến, được xác định bằng các quy tắc không sử dụng biến mục tiêu. Trong lần chạy hiện tại, schema mã hóa, vocabulary và nhóm danh mục hiếm được tạo trước khi chia dữ liệu. Đây không phải *target leakage* vì không dùng giá trị nhãn, nhưng validation fold đã đóng góp thông tin về vocabulary/tần suất. Nhóm giữ quy trình này cho phạm vi đồ án và diễn giải RMSE CV như metric nội bộ của pipeline hiện tại, không như một ước lượng độc lập hoàn toàn. Với các mô hình tuyến tính, **StandardScaler** vẫn được *fit* trên phần huấn luyện của từng fold; các mô hình cây sử dụng trực tiếp đặc trưng số đã mã hóa.

Bảng 6: Các bước tiền xử lý và feature engineering chính

| Nhóm bước              | Mô tả                                                                                |
|------------------------|--------------------------------------------------------------------------------------|
| Chuẩn hóa kiểu dữ liệu | Chuyển RAM, storage, kích thước màn hình và giá về dạng số                           |
| Xử lý thiếu            | Tạo cờ missing/no-info cho brand, model, CPU, GPU, RAM, storage và màn hình          |
| Mã hóa phân loại       | One-hot brand, model, CPU brand/family, warranty và brand segment                    |
| Trích xuất cấu hình    | Tách CPU tier, GPU tier, loại storage SSD/HDD và thế hệ CPU                          |
| Feature engineering    | Tạo ram_storage_product_scaled, ram_storage_balance và memory_storage_score          |
| Target transformation  | So sánh target_price với log_target_price, sau đó chọn target_price cho mô hình cuối |

Hai target được đánh giá trên cùng một cách chia mẫu. Khi mô hình học `log_target_price`, dự đoán được biến đổi ngược về đơn vị triệu VND trước khi tính các chỉ số. Điều này bảo đảm MAE, RMSE,  $R^2$  và MAPE có thể so sánh công bằng với mô hình học trực tiếp trên giá gốc.


### 3.2 Lựa chọn và đặc điểm mô hình

Nhóm khảo sát baseline tuyến tính (Linear Regression, Ridge, Lasso, Elastic Net), ensemble bagging (Random Forest, Extra Trees) và gradient boosting (LightGBM, CatBoost). Hai mô hình boosting được tinh chỉnh tiếp vì phù hợp với dữ liệu bảng có nhiều tương tác phi tuyến.

Bảng 7 cho thấy các mô hình boosting dẫn đầu trong thí nghiệm cuối. CatBoost học trực tiếp giá đạt RMSE 5,314 triệu VND và  $R^2 = 0,894$ ; LightGBM học giá trực tiếp đạt RMSE 5,360 triệu VND và  $R^2 = 0,892$ . LightGBM học biến mục tiêu log có MAE thấp nhất trong bảng (3,192 triệu VND), nhưng RMSE cao hơn một chút. Random Forest và Extra Trees cho kết quả cạnh tranh nhưng thấp hơn hai mô hình boosting. LightGBM và CatBoost được đưa vào tinh chỉnh vì thuộc nhóm có RMSE thấp nhất,  $R^2$  cao nhất và kết quả ổn định qua các fold; các mô hình tuyến tính được giữ làm baseline, không phải ứng viên tinh chỉnh chính.

Bảng 7: So sánh các mô hình trong thí nghiệm modeling final

| Model         | Loại              | Target           | MAE   | RMSE  | R2    | MAPE   |
|---------------|-------------------|------------------|-------|-------|-------|--------|
| CatBoost      | gradient_boosting | target_price     | 3.282 | 5.314 | 0.894 | 28.97% |
| LightGBM      | gradient_boosting | target_price     | 3.228 | 5.360 | 0.892 | 27.42% |
| LightGBM      | gradient_boosting | log_target_price | 3.192 | 5.407 | 0.890 | 25.28% |
| Random Forest | tree_ensemble     | target_price     | 3.377 | 5.660 | 0.880 | 29.11% |
| CatBoost      | gradient_boosting | log_target_price | 3.264 | 5.699 | 0.878 | 25.32% |
| Random Forest | tree_ensemble     | log_target_price | 3.331 | 5.727 | 0.877 | 26.76% |
| Extra Trees   | tree_ensemble     | target_price     | 3.539 | 6.099 | 0.860 | 30.12% |
| Extra Trees   | tree_ensemble     | log_target_price | 3.513 | 6.123 | 0.859 | 28.70% |



Hình 6: So sánh RMSE giữa biến mục tiêu giá gốc và biến mục tiêu log theo từng mô hình.

Với tiêu chí RMSE trên thang giá thực, `target_price` được chọn làm mục tiêu chính; `target log` được giữ làm đối chứng cho sai số tương đối. Chênh lệch RMSE giữa CatBoost và LightGBM trên giá gốc chỉ khoảng 0,9%, nên cả hai được giữ lại để tinh chỉnh.

### 3.3 Cấu hình huấn luyện và tinh chỉnh siêu tham số

Hàm mất mát chính của LightGBM là hồi quy bình phương (`objective=regression`); CatBoost dùng `loss_function=RMSE`. Hai hàm này đều phạt mạnh sai số lớn, phù hợp với mục tiêu giảm các dự đoán lệch nhiều ở phân khúc giá cao. Các chỉ số báo cáo gồm MAE để phản ánh sai số điển hình, RMSE để nhạy với sai số lớn,  $R^2$  để đo phần biến thiên được giải thích và MAPE để theo dõi sai số tương đối. Do MAPE nhạy với các quan sát có giá nhỏ, chỉ số này chỉ được dùng bổ sung, không phải tiêu chí chính để lựa chọn mô hình.

Cấu hình baseline của LightGBM dùng 500 cây, `learning_rate=0,05` và `num_leaves=31`. CatBoost baseline dùng 500 vòng boosting, `learning_rate=0,05` và độ sâu cây bằng 6. Cả hai sử dụng seed 42. Các tham số này tạo điểm xuất phát có độ phức tạp vừa phải trước khi mở rộng không gian tìm kiếm.

Việc tinh chỉnh dùng `RandomizedSearchCV` thay vì Grid Search để khảo sát hiệu quả không gian tham số lớn. Mỗi mô hình thử 40 cấu hình trên 5 fold được phân tầng theo năm nhóm phân vị giá, dùng `neg_root_mean_squared_error` làm scoring; tập holdout không tham gia quá trình này. Với LightGBM, không gian tìm kiếm gồm số cây (500–1.600), learning rate (0,01–0,08), số lá, độ sâu, `min_child_samples`, tỷ lệ lấy mẫu hàng/cột và hệ số regularization  $L_1/L_2$ . Với CatBoost, các tham số gồm số vòng lặp (500–1.600), learning rate, độ sâu (4–10), `12_leaf_reg`, `bagging_temperature` và `random_strength`.

LightGBM tốt nhất có 1.600 cây, learning rate 0,03, 15 lá, độ sâu 10 và `reg_alpha=1`, đạt RMSE CV 5,365 triệu VND. CatBoost tốt nhất dùng 1.600 vòng, learning rate 0,08, depth 7, `12_leaf_reg=10`, `bagging_temperature=5` và `random_strength=2`, đạt RMSE CV 5,226 triệu VND.

Kết quả `RandomizedSearchCV` cho thấy CatBoost sau tinh chỉnh đạt RMSE CV trung bình thấp nhất,  $5,226 \pm 0,263$  triệu VND, nên được lựa chọn theo quy trình CV đã định trước khi quan sát tập holdout. Các cấu hình baseline cũng được tính trên cùng bộ fold để so sánh nhất quán. Đây không phải nested CV, do đó chỉ số CV sau search được dùng cho lựa chọn cấu hình chứ không được diễn giải như một ước lượng độc lập hoàn toàn của sai số tổng quát hóa.

Trên tập holdout, LightGBM baseline (chưa tinh chỉnh) đạt RMSE 5,785 triệu VND, trong khi CatBoost sau tinh chỉnh đạt 5,913 triệu VND, tương ứng chênh lệch 2,21%. Nhóm giữ CatBoost vì đây là cấu hình được chọn trước bằng RMSE CV, đồng

thời chênh lệch holdout giữa hai ứng viên nhỏ. Quyết định này nhằm giữ nhất quán quy trình, không hàm ý CatBoost vượt trội LightGBM trên mọi phép chia. Holdout được xem là *evaluation holdout* dùng để tham chiếu hiệu năng của cấu hình trước khi huấn luyện lại trên toàn bộ dữ liệu.

Bảng 8: Kết quả baseline và tuned cho LightGBM/CatBoost trên holdout

| Model    | Phiên bản | MAE   | RMSE  | R2    | MAPE   | Median AE |
|----------|-----------|-------|-------|-------|--------|-----------|
| LightGBM | baseline  | 3.367 | 5.785 | 0.856 | 31.90% | 1.918     |
| CatBoost | baseline  | 3.474 | 5.819 | 0.854 | 33.51% | 2.058     |
| LightGBM | tuned     | 3.370 | 5.842 | 0.853 | 31.67% | 1.874     |
| CatBoost | tuned     | 3.373 | 5.913 | 0.849 | 32.25% | 1.943     |

## 4 Kết quả và Thảo luận

Phần này đánh giá các phiên bản mô hình huấn luyện trên 5.836 mẫu phát triển và dự đoán tập holdout gồm 1.460 mẫu. Các phiên bản này khác artifact đang chạy trong ứng dụng, vốn được fit lại trên cả 7.296 mẫu; do đó không metric nào trong chương được gán trực tiếp cho artifact đang chạy. Vì bài toán là hồi quy dự đoán giá liên tục, các chỉ số Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn không phù hợp; chúng chỉ có ý nghĩa khi nhận thuộc các lớp rời rạc. Thay vào đó, nhóm dùng MAE, RMSE,  $R^2$ , MAPE, residual và sai số theo phân khúc giá. Toàn bộ giá trị sai số trong chương được tính theo triệu VND.

Residual của quan sát thứ  $i$  được định nghĩa là:


$$e_i = y_i - \hat{y}_i, \quad (3)$$

trong đó  $y_i$  là giá thực tế và  $\hat{y}_i$  là giá dự đoán. Vì vậy, residual âm biểu thị dự đoán cao hơn thực tế, còn residual dương biểu thị dự đoán thấp hơn thực tế.

### 4.1 Kết quả thực nghiệm

#### 4.1.1 Learning curves và khả năng tổng quát hóa

Do các mô hình được chọn là ensemble cây thay vì mạng neural huấn luyện theo epoch, nhóm sử dụng learning curve theo kích thước tập huấn luyện để đánh giá khả năng tổng quát hóa. Đường cong thể hiện RMSE trung bình trên phần huấn luyện và validation khi số lượng mẫu huấn luyện tăng dần.



Hình 7: Learning curve RMSE của CatBoost sau tinh chỉnh (trái) và LightGBM baseline (phải).

Khi số mẫu train tăng từ 933 lên 4.668, validation RMSE của CatBoost giảm từ 6,534 xuống 5,243 triệu VND (cải thiện 19,76%); LightGBM giảm từ 6,983 xuống 5,476 triệu VND (21,58%). Cả hai đường validation vẫn tiếp tục giảm ở kích thước lớn nhất, nên kết quả nhất quán với khả năng mô hình hưởng lợi từ dữ liệu bổ sung. Khoảng cách đáng kể giữa train và validation là dấu hiệu của overfitting/phương sai, nhưng learning curve này không đủ để xác định đó là nguyên nhân duy nhất hay chính yếu, vì nhiễu ngẫu nhiên và thiếu đặc trưng cũng có thể làm tăng sai số validation.

Tuy nhiên, khoảng cách train-validation ở kích thước lớn nhất vẫn lần lượt là 2,201 triệu VND với CatBoost và 1,970 triệu VND với LightGBM. Đây là khoảng cách đáng kể về mặt thực tiễn, đặc biệt khi so với mức giá trung vị 7,89 triệu VND của Chợ Tốt; tuy nhiên, không nên quy đổi trực tiếp chênh lệch giữa hai RMSE thành phần trăm sai số của từng sản phẩm. Kết quả cho thấy nhu cầu cải thiện khả năng tổng quát thay vì gán nhãn định tính “nhẹ” hay “nặng”. Các hướng cần kiểm tra gồm bổ sung dữ liệu, regularization, early stopping và đưa toàn bộ preprocessing vào pipeline của từng fold.

#### 4.1.2 Đánh giá trên tập holdout


Bảng 9 so sánh bốn ứng viên sau khi cố định quy trình ở Chương 3. LightGBM baseline có RMSE thấp nhất (5,785 triệu VND), trong khi CatBoost sau tinh chỉnh có MAE gần tương đương (3,373 triệu VND) nhưng RMSE cao hơn 5,913 triệu VND.  $R^2$  của các ứng viên nằm trong khoảng 0,849–0,856, cho thấy mô hình mô tả được khoảng 85% biến thiên của giá trên tập holdout. Kết quả này không hàm ý rằng các đặc trưng có quan hệ nhân quả với giá.

Bảng 9: Metric holdout cuối cùng của các candidate

| Model             | MAE   | RMSE  | R2    | MAPE   | Max error | Mean residual |
|-------------------|-------|-------|-------|--------|-----------|---------------|
| LightGBM_baseline | 3.367 | 5.785 | 0.856 | 31.90% | 51.698    | -0.059        |
| CatBoost_baseline | 3.474 | 5.819 | 0.854 | 33.51% | 51.910    | -0.041        |
| LightGBM_tuned    | 3.370 | 5.842 | 0.853 | 31.67% | 51.817    | -0.047        |
| CatBoost_tuned    | 3.373 | 5.913 | 0.849 | 32.25% | 56.171    | -0.064        |

Mặc dù LightGBM baseline đạt RMSE holdout thấp hơn, CatBoost sau tinh chỉnh vẫn là mô hình được lựa chọn theo quy trình CV đã định trước. Việc đổi mô hình sau khi quan sát holdout sẽ dùng tập này như một tập validation bổ sung và làm tăng nguy cơ lựa chọn theo nhiều của một lần chia dữ liệu. Tuy nhiên, kết quả holdout không cho thấy CatBoost vượt trội LightGBM baseline; hai mô hình nên được xem là các ứng viên có hiệu năng gần nhau trong phạm vi biến động của phép chia hiện tại. MAPE của các mô hình khoảng 31,67–33,51%; chỉ số này cần đọc thận trọng vì những laptop giá thấp có thể làm tỷ lệ sai số tăng mạnh.

Hai nguồn đại diện chủ yếu cho hai cơ chế giá khác nhau, nhưng mô hình không dùng trực tiếp tên website. Thay vào đó, `condition_score` biểu diễn tình trạng theo thứ tự: 1 cho máy kém/đã sửa chữa, 2 cho máy đã sử dụng hoặc không rõ tình trạng, và 3 cho máy mới. Biến này cho phép mô hình phân biệt trạng thái khi thông tin được cung cấp. Trong dữ liệu hiện tại, toàn bộ 4.382 dòng Websosanh có `condition_clean=Unknown` và được điền ở mức 2; vì vậy `condition_score` không tự nó phân biệt hoàn hảo hai nguồn. Phạm vi báo cáo chỉ đánh giá tập hợp nhất và không mở rộng thêm metric riêng theo nguồn.



Hình 8: Giá thực tế so với dự đoán (trái) và residual theo giá thực tế (phải) của CatBoost sau tinh chỉnh trên holdout.

Các điểm ở vùng giá thấp-trung bình tập trung tương đối sát đường lý tưởng  $y = \hat{y}$ . Khi giá tăng, độ phân tán quanh đường này lớn hơn rõ rệt; biểu đồ residual xác nhận phương sai sai số tăng theo giá (heteroscedasticity). Do đó, một chỉ số tổng thể không đủ mô tả chất lượng dự đoán ở mọi phân khúc.

## 4.2 So sánh và thảo luận

### 4.2.1 Sai số theo phân khúc giá

Bảng 10: Lỗi của CatBoost\_tuned theo phân khúc giá

| Segment | N   | Mean price | MAE   | RMSE   | MAPE   | Mean residual |
|---------|-----|------------|-------|--------|--------|---------------|
| Q1_low  | 292 | 3.084      | 1.826 | 2.805  | 69.82% | -1.509        |
| Q2      | 292 | 6.367      | 1.722 | 2.575  | 27.49% | -0.882        |
| Q3      | 293 | 10.447     | 2.706 | 3.927  | 26.27% | -0.478        |
| Q4      | 291 | 16.706     | 3.043 | 4.234  | 18.33% | -0.101        |
| Q5_high | 292 | 38.018     | 7.567 | 11.268 | 19.33% | 2.649         |

Bảng 10 làm rõ hai dạng sai lệch. Ở Q1, MAPE cao nhất (69,82%) dù MAE chỉ 1,826 triệu VND, vì mẫu số giá thực tế nhỏ; đây là lý do MAPE không được dùng làm tiêu chí chọn chính. Ngược lại, Q5 có MAE 7,567 và RMSE 11,268 triệu VND, cao nhất trong



các phân khúc, phản ánh khó khăn khi định giá laptop cao cấp có cấu hình và định vị sản phẩm đa dạng.

Residual trung bình âm ở Q1–Q4 cho thấy xu hướng dự đoán cao hơn giá thực tế ở phần lớn thị trường phổ thông. Ở Q5, residual trung bình dương 2,649 triệu VND cho thấy mô hình có xu hướng dự đoán thấp hơn giá thực tế ở phân khúc cao. Mẫu sai lệch này nhất quán với giả thuyết dự đoán bị co về vùng giá phổ biến, nhưng không đủ để xác lập cơ chế đó. Các giải thích cùng phù hợp khác gồm Q5 có ít quan sát hơn trong từng nhóm cấu hình, thiếu đặc trưng phân biệt sản phẩm cao cấp và nhiều nhân lớn hơn ở phân khúc này.

#### 4.2.2 Các trường hợp sai số điển hình

Bảng 11: Các mẫu có lỗi tuyệt đối lớn nhất

| Index | Actual  | Predicted | Residual | Abs error | APE    | RAM     | Storage | Screen |
|-------|---------|-----------|----------|-----------|--------|---------|---------|--------|
| 5913  | 62.000  | 118.171   | -56.171  | 56.171    | 90.60% | 64.000  | 2,048   | 16.000 |
| 6739  | 76.900  | 24.711    | 52.189   | 52.189    | 67.87% | 16.000  | 512.000 | 15.600 |
| 7187  | 50.999  | 98.311    | -47.312  | 47.312    | 92.77% | 32.000  | 2,048   | 17.000 |
| 6262  | 110.990 | 71.046    | 39.944   | 39.944    | 35.99% | 128.000 | 512.000 | 14.000 |
| 5661  | 63.050  | 98.221    | -35.171  | 35.171    | 55.78% | 32.000  | 2,048   | 17.300 |
| 5967  | 153.290 | 118.129   | 35.161   | 35.161    | 22.94% | 64.000  | 6,144   | 18.000 |
| 7056  | 86.990  | 121.517   | -34.527  | 34.527    | 39.69% | 64.000  | 2,048   | 16.000 |
| 6501  | 58.899  | 26.890    | 32.009   | 32.009    | 54.35% | 16.000  | 512.000 | 14.000 |

Các lỗi tuyệt đối lớn nhất đều xuất hiện ở Q5. Một số mẫu có RAM 16–64GB và lưu trữ 512GB–2TB vẫn có giá thực tế chênh nhiều so với dự đoán, ví dụ quan sát có `sample_index=6739` có giá thực tế 76,900 triệu VND nhưng được dự đoán 24,711 triệu VND. Điều này cho thấy cấu hình phần cứng cơ bản chưa mô tả đầy đủ các yếu tố định giá ở laptop cao cấp, như thế hệ CPU/GPU cụ thể, màn hình, thương hiệu cao cấp, đặc tính workstation/gaming, thời điểm niêm yết và chính sách bán hàng.

Ở chiều ngược lại, quan sát có `sample_index=5913` có giá thực tế 62,000 triệu VND nhưng dự đoán 118,171 triệu VND. Thông số RAM/lưu trữ rất cao có thể làm mô hình liên hệ với nhóm sản phẩm cao cấp hơn; các khả năng khác gồm khuyến mãi, khác biệt cấu hình chi tiết, lỗi phân tích chuỗi hoặc nhiễu thu thập. Do dữ liệu đã loại toàn bộ nhóm cấu hình lắp mềm khỏi tập mô hình, khả năng tham chiếu nhiều quan sát giá cho cấu hình tương tự cũng giảm. Các mẫu sai số lớn chưa được audit thủ công bằng tiêu đề và URL gốc, nên các nguyên nhân trên chỉ là giả thuyết chẩn đoán, không phải kết luận đã được kiểm chứng.

Tổng quan, trong 1.460 mẫu holdout, CatBoost sau tinh chỉnh có 665 trường hợp

dự đoán thấp và 795 trường hợp dự đoán cao; residual trung bình là  $-0,064$  triệu VND. Residual trung bình gần 0 không có nghĩa mô hình không có sai lệch hệ thống: xu hướng dự đoán cao ở các phân khúc thấp và dự đoán thấp ở phân khúc cao có thể triệt tiêu nhau khi tính trung bình trên toàn bộ holdout. Các hướng cải thiện trong phạm vi hiện tại là bổ sung dữ liệu premium và đặc trưng CPU/GPU, tình trạng sản phẩm chi tiết hơn.

Tóm lại, các mô hình boosting cho hiệu năng tốt trên dữ liệu bảng đa nguồn. LightGBM baseline đạt RMSE thấp nhất trên tập holdout, trong khi CatBoost sau tinh chỉnh là mô hình được lựa chọn theo quy trình CV đã định trước. Kết quả hiện tại không đủ để khẳng định một trong hai mô hình vượt trội tuyệt đối.

Sai số không phân bố đồng đều giữa các mức giá. Mô hình có MAE và RMSE tuyệt đối thấp hơn ở các phân khúc phổ thông, đồng thời có xu hướng dự đoán cao đối với sản phẩm giá thấp và dự đoán thấp đối với sản phẩm cao cấp. Các trường hợp sai số lớn gợi ý các đặc trưng hiện tại chưa phản ánh đầy đủ thể hệ CPU/GPU, định vị sản phẩm, chất lượng màn hình, tình trạng máy, thời điểm niêm yết và chính sách bán hàng; các nguyên nhân cụ thể chưa được audit trực tiếp.

Các hạn chế chính gồm khoảng cách train-validation còn đáng kể, dữ liệu phân khúc cao cấp còn hạn chế, quy tắc lọc lặp mềm không hoàn toàn trùng với khóa hợp nhất và schema/gom nhóm hiếm được xác định trước khi chia fold. Các điểm này được ghi nhận để giới hạn phạm vi diễn giải kết quả.


## 5 Xây dựng và Triển khai Ứng dụng

Sau khi lựa chọn mô hình ở Phần 3 và đánh giá ở Phần 4, nhóm xây dựng ứng dụng web *Laptop Price Studio* để đưa mô hình vào sử dụng. Ứng dụng nhận cấu hình laptop, trả về giá ước tính theo triệu VND kèm khoảng giá tham khảo, đồng thời hỗ trợ so sánh nhiều tin rao và khảo sát phản ứng dự đoán khi thay đổi RAM và dung lượng lưu trữ. Phiên bản hiện tại được triển khai cục bộ (local); do đó không có URL cloud công khai.

### 5.1 Kiến trúc hệ thống và tích hợp mô hình

Hệ thống sử dụng kiến trúc client-server đơn giản, gồm giao diện web, API dự đoán và các thành phần mô hình. Frontend được xây dựng bằng HTML, CSS và JavaScript thuần; backend dùng Python với `ThreadingHTTPServer`. Khi chạy `app/backend/server.py`, cùng một tiến trình vừa cung cấp các tệp tĩnh của frontend, vừa cung cấp API tại cổng 8000. Do frontend và API được phục vụ từ cùng host và cổng, ứng dụng không cần cấu hình CORS cho luồng sử dụng local mặc định.

Kiến trúc và luồng xử lý của Laptop Price Studio



Hình 9: Kiến trúc và luồng xử lý của ứng dụng Laptop Price Studio.

Luồng xử lý chính được mô tả như sau:

1. Người dùng nhập cấu hình bằng biểu mẫu thủ công hoặc mô tả tự nhiên trên trình duyệt.
2. JavaScript gửi yêu cầu JSON đến API `/api/predict`. Với biểu mẫu thủ công, dữ liệu được gửi trực tiếp; với mô tả tự nhiên, backend gọi Gemini API để trích xuất 14 trường cấu hình thô.
3. Backend kiểm tra dữ liệu, chuẩn hóa và mã hóa bằng `LaptopFeatureEncoder`. Bộ mã hóa chuyển 14 trường đầu vào thành đúng 86 đặc trưng số theo thứ tự mà mô hình yêu cầu.
4. Sau khi kiến trúc và siêu tham số được cố định từ quy trình đánh giá, CatBoost được huấn luyện lại trên toàn bộ 7.296 mẫu để tạo artifact chạy trong ứng dụng local. Artifact được lưu tại `models/final_laptop_price_model_full_data.joblib`, được nạp một lần bằng `joblib` khi server khởi động và tái sử dụng cho các yêu cầu dự đoán. Các chỉ số MAE/RMSE/ $R^2$  ở Phần 4 được đo trên phiên bản CatBoost huấn luyện với 5.836 mẫu, trong khi artifact đang chạy được huấn luyện trên toàn bộ 7.296 mẫu, bao gồm cả 1.460 mẫu holdout. Do đó, *không có metric ngoài mẫu nào đánh giá trực tiếp artifact đang chạy*; không được gán RMSE 5,913 hay  $R^2 \approx 0,85$  cho đầu ra của ứng dụng. Các metric holdout chỉ cung cấp bằng chứng gián tiếp về một phiên bản huấn luyện khác; learning curve cũng không thay thế được đánh

giá độc lập. Vì vậy từ “production” trong tên tệp/quy trình chỉ mô tả vai trò kỹ thuật, không hàm ý artifact đã đủ điều kiện vận hành thực tế.

5. Mô-đun tạo khoảng giá tham khảo sử dụng RMSE theo phân khúc, mức độ đầy đủ của đầu vào và các cờ thiếu thông tin để điều chỉnh độ rộng quanh giá dự đoán điểm. Khoảng này được xây dựng theo quy tắc thực nghiệm, không được diễn giải như khoảng tin cậy hoặc khoảng dự đoán có bảo đảm xác suất.
6. API trả JSON; frontend hiển thị giá trung tâm, khoảng giá tham khảo, tỷ lệ hoàn thiện dữ liệu, mức cảnh báo theo quy tắc và các thông báo kiểm tra dữ liệu.

Các API bổ sung gồm `/api/compare` để so sánh 2–10 laptop, `/api/config-sweep` để tạo dữ liệu biểu đồ RAM–dung lượng lưu trữ, `/api/price-interval-config` để đọc cấu hình khoảng giá và `/api/health` để kiểm tra trạng thái dịch vụ. Các tệp mô hình, schema 86 đặc trưng và cấu hình khoảng giá được đặt tách biệt trong thư mục `models/`; vì vậy có thể thay mô hình mới mà không cần sửa giao diện, miễn là duy trì cùng hợp đồng đặc trưng.

`ThreadingHTTPServer` được lựa chọn để đơn giản hóa việc chạy local và trình diễn sản phẩm. Kiến trúc hiện tại chưa hướng đến tải truy cập lớn, quản lý nhiều tiến trình hoặc triển khai Internet công khai. Khi chuyển sang môi trường production, backend cần được đặt sau một máy chủ ứng dụng (*application server*) và reverse proxy phù hợp, đồng thời bổ sung HTTPS, giới hạn yêu cầu, xác thực và giám sát.

Bảng 12: Các thành phần chính của ứng dụng.

| Thành phần                  | Vai trò                                                                                                    |
|-----------------------------|------------------------------------------------------------------------------------------------------------|
| Frontend                    | Thu nhận dữ liệu, gọi API và hiển thị kết quả dự đoán, bảng so sánh, biểu đồ.                              |
| Backend API                 | Phục vụ tệp tĩnh, xác thực yêu cầu, điều phối mã hóa, dự đoán và trả JSON.                                 |
| Feature encoder             | Chuẩn hóa thông số laptop và tạo 86 đặc trưng số đúng schema mô hình.                                      |
| CatBoost model              | Ước tính giá trung tâm từ vector đặc trưng đã mã hóa.                                                      |
| Mô-đun khoảng giá tham khảo | Điều chỉnh độ rộng khoảng giá theo RMSE phân khúc và mức thiếu thông tin; không cung cấp bảo đảm xác suất. |
| Gemini API (tùy chọn)       | Trích xuất cấu hình có cấu trúc từ mô tả tự nhiên; không cần cho chế độ nhập thủ công.                     |

## 5.2 Giao diện và chức năng

Giao diện được thiết kế theo hướng một trang, ưu tiên thao tác nhanh. Khu vực đầu vào cho phép chuyển giữa chế độ *Mô tả* và *Thủ công*. Chế độ mô tả phù hợp khi người dùng có nội dung tin rao; chế độ thủ công cho phép điền trực tiếp hãng, dòng máy, RAM, dung lượng lưu trữ, màn hình, CPU, GPU, tình trạng và bảo hành. Chế độ thủ công không yêu cầu khóa Gemini API.

Sau khi dự đoán, ứng dụng hiển thị khoảng giá tham khảo, giá trung tâm, tỷ lệ hoàn thiện dữ liệu và mức cảnh báo theo quy tắc. Độ rộng được tính từ RMSE của phân khúc giá và hệ số phạt thông tin thiếu; cả RMSE và các ngưỡng phân khúc trong `price_interval_config.json` được tạo từ phân tích holdout. Vì holdout đã tham gia cấu hình đầu ra này, nó không còn là tập đánh giá độc lập cho toàn bộ hệ thống. Ngoài ra, phân khúc khi suy luận được chọn theo giá dự đoán, trong khi bảng RMSE được tính theo phân khúc giá thực tế. Do sự khác nhau này và do chưa đo tỷ lệ bao phủ trên một tập khác, khoảng trên không phải prediction interval đã hiệu chỉnh và các nhãn thấp/trung bình/cao không mang nghĩa xác suất.

Ngoài dự đoán một máy, người dùng có thể nhập nhiều tin rao trong chế độ *Số sánh*; hệ thống trích xuất từng máy, dự đoán giá tham khảo và tính tỷ lệ chênh lệch giữa giá rao và giá dự đoán:

$$d = \frac{P_{\text{listed}} - P_{\text{predicted}}}{P_{\text{predicted}}} \times 100\%. \quad (4)$$

Giá trị  $d$  âm cho thấy giá rao thấp hơn mức mô hình ước lượng, trong khi  $d$  dương cho thấy giá rao cao hơn. Phiên bản triển khai hiện tại xếp hạng chính theo chênh lệch tuyệt đối  $P_{\text{predicted}} - P_{\text{listed}}$  (triệu VND);  $d$  được dùng để mô tả chênh lệch tương đối và gắn nhãn. Vì vậy, thứ hạng có thể ưu tiên một laptop đắt tiền có mức tiết kiệm tuyệt đối lớn hơn, ngay cả khi tỷ lệ tiết kiệm thấp hơn một laptop rẻ. Các ngưỡng nhãn là quy tắc sản phẩm, chưa được validation như một bài toán quyết định và không tính trực tiếp độ bất định vào thứ hạng. Kết quả chỉ là tham khảo vì mô hình không quan sát đầy đủ ngoại hình, tình trạng pin, bảo hành thực tế, phụ kiện, uy tín người bán và chất lượng hoàn thiện của từng máy.

Hệ thống tính mức độ đầy đủ và gắn cảnh báo cho dữ liệu thiếu, nhưng code xếp hạng hiện tại không loại, hạ bậc hay điều chỉnh điểm theo cảnh báo và độ bất định. Mọi sản phẩm vẫn được sắp xếp theo chênh lệch tuyệt đối; cảnh báo chỉ được hiển thị kèm kết quả.

Với một cấu hình nhập thủ công hợp lệ, biểu đồ RAM–dung lượng lưu trữ tính dự đoán trên các mức định nghĩa trước, trong khi giữ nguyên các thuộc tính còn lại. Biểu đồ mô tả phản ứng của mô hình, không ước lượng tác động nhân quả của nâng cấp. Hệ thống hiện chưa kiểm tra khả năng tương thích phần cứng hoặc cảnh báo đầy đủ cấu hình ngoài phân phối, nên người dùng không nên diễn giải mọi điểm sinh tự động là một

sản phẩm khả thi trên thị trường.

The screenshot shows the 'Price Studio' application interface. At the top, there's a header with 'LP Price Studio' and a 'Không kết nối' (Not connected) status. Below the header, a large section titled 'Nhập cấu hình nhận khoảng giá dự đoán.' (Enter configuration to receive price prediction.) contains two buttons: 'Bắt đầu nhập' (Start input) and 'Điền mẫu' (Fill sample). The main area is divided into two columns. The left column, labeled 'ĐẦU VÀO' (Input), has a sub-header 'Chọn cách nhập thông tin máy.' (Choose how to input machine info.) with tabs for '1 máy' (1 machine), 'So sánh' (Compare), 'Mô tả' (Description), and 'Thủ công' (Manual). Under the '1 máy' tab, there's a text area for 'Mô tả tự nhiên' (Natural description) containing the text: 'Dell Inspiron 15, Intel Core i5-1235U, RAM 16GB, SSD 512GB, màn 15.6 inch, card Intel Integrated, đã sử dụng chưa sửa chữa, hết bảo hành'. Below this are buttons for 'Dự đoán giá' (Predict price) and 'Xóa form' (Clear form). The right column, labeled 'KẾT QUẢ' (Result), has a sub-header 'Hoàn tất' (Completed). It displays a 'KHOẢNG GIÁ DỰ ĐOÁN' (Price prediction range) of '5.750.000đ - 13.600.000đ' with a 'Giá trung tâm: 9.672.000đ' (Center price: 9,672,000đ). Below this are buttons for 'HOÀN THIỆN INPUT: 100%' and 'SỐ TÍN CẬY: CAO' (High confidence). A 'Chi tiết' (Details) section lists four OK status items: 'Đã phân tích mô tả và trích xuất cấu hình.', 'Đã kiểm tra các giá trị nhập vào.', 'Đã chuẩn bị dữ liệu để ước tính giá.', and 'Đã thông tin chính; khoảng giá dựa trên độ chính xác theo phân khúc giá.'

Hình 10: Màn hình chính của ứng dụng: nhập mô tả tự nhiên và hiển thị kết quả dự đoán.

The screenshot shows the 'So sánh & xếp hạng' (Compare & Rank) section of the application. It features a sub-header 'Chọn cách nhập thông tin máy.' with tabs for '1 máy' and 'So sánh'. Below the tabs, a list of three laptops is shown: Laptop A (RAM 8GB, SSD 512GB, CPU Intel Core i5, đã sử dụng, giá 12.000.000 VND), Laptop B (RAM 16GB, SSD 512GB, CPU Intel Core i5, đã sử dụng, giá 14.000.000 VND), and Laptop C (RAM 16GB, SSD 1TB, CPU Intel Core i7, đã sử dụng, giá 18.000.000 VND). Below the list are buttons for 'So sánh & xếp hạng' and 'Xóa form'. The main section, titled 'So sánh & xếp hạng', has a sub-header 'Hoàn tất' and a 'KẾT LUẬN SO SÁNH' (Comparison Conclusion) section. This section includes a title 'Laptop C' and a note: 'Laptop C đang có lợi nhất: giá rao 18.00 triệu, model dự đoán 15.59 triệu (đắt so với cấu hình).' Below this is a table with the following data:

| HẠNG | LAPTOP   | GIÁ THỰC TẾ | GIÁ DỰ ĐOÁN | CHỖNH LỆCH            | NHẬN XÉT                            |
|------|----------|-------------|-------------|-----------------------|-------------------------------------|
| #1   | Laptop C | 18.000.000đ | 15.586.000đ | +2.414.000đ (+15.49%) | <a href="#">Đắt so với cấu hình</a> |
| #2   | Laptop B | 14.000.000đ | 11.267.000đ | +2.733.000đ (+24.26%) | <a href="#">Đắt so với cấu hình</a> |
| #3   | Laptop A | 12.000.000đ | 6.868.000đ  | +5.132.000đ (+74.72%) | <a href="#">Đắt so với cấu hình</a> |

Below the table is a 'Chi tiết' (Details) section with four OK status items: 'Đã phân tích 3 laptop kèm giá bán.', 'Mỗi máy đã được ước tính giá tham khảo.', 'Xếp hạng theo mức chênh lệch giữa giá dự đoán và giá rao bán.', and 'Laptop C đang có lợi nhất: giá rao 18.00 triệu, model dự đoán 15.59 triệu (đắt so với cấu hình).'

Hình 11: Chức năng so sánh và xếp hạng nhiều laptop theo giá rao và giá dự đoán.



Hình 12: Biểu đồ khảo sát giá dự đoán theo RAM và dung lượng lưu trữ.

### 5.3 Triển khai local và hướng dẫn sử dụng

Ứng dụng được triển khai local trên máy phát triển, với địa chỉ mặc định <http://127.0.0.1:8000>. Yêu cầu môi trường là Python 3.10 trở lên và `pip`. Khóa Gemini chỉ cần khi dùng nhập mô tả tự nhiên hoặc so sánh; người dùng vẫn có thể dự đoán từ biểu mẫu thủ công mà không gọi Gemini.

Khi sử dụng chế độ mô tả tự nhiên hoặc so sánh, nội dung người dùng nhập được gửi đến Gemini API để trích xuất cấu hình. Vì vậy, người dùng không nên nhập thông tin cá nhân hoặc dữ liệu nhạy cảm. Chế độ nhập thủ công không gửi dữ liệu đến dịch vụ bên ngoài.

Trước khi khởi động, cần bảo đảm các tệp mô hình, schema đặc trưng và cấu hình khoảng giá tồn tại trong thư mục `models/`. Cụ thể, backend cần tệp `final_laptop_price_model_full`, `final_laptop_price_feature_schema.json` và `price_interval_config.json`. Nếu tệp mô hình thiếu, endpoint health sẽ trả `model_available: false`; khi đó chức năng dự đoán không thể thực hiện.

Từ thư mục gốc của dự án, thực hiện các lệnh sau trên Linux/macOS:

Listing 1: Cài đặt môi trường và phụ thuộc.

```
1 python3 -m venv .venv
2 source .venv/bin/activate
3 python3 -m pip install --upgrade pip
4 python3 -m pip install -r requirements.txt
```

Trên Windows PowerShell, thay lệnh kích hoạt bằng:

```
1 .venv\Scripts\Activate.ps1
```

Các thư viện có ảnh hưởng trực tiếp đến khả năng nạp mô hình, gồm `catboost` và `joblib`, đã được khóa phiên bản trong `requirements.txt`. Chức năng Gemini dùng REST API thông qua `requests`, cũng đã được khóa phiên bản, nên không cần cài một SDK Gemini riêng.

Để bật các chức năng ngôn ngữ tự nhiên, sao chép tệp cấu hình và điền khóa API cá nhân. Không đưa tệp `.env` chứa khóa lên kho mã nguồn.

Listing 2: Cấu hình tùy chọn cho Gemini API.

```
1 cp app/backend/.env.example app/backend/.env
2 # S a app/backend/.env: GEMINI_API_KEY=<khoa_API_cua_ban>
```

Khởi động ứng dụng bằng một lệnh:

Listing 3: Chạy ứng dụng local.

```
1 python3 app/backend/server.py
```

Sau đó mở <http://127.0.0.1:8000> trên trình duyệt. Có thể kiểm tra nhanh backend bằng lệnh `curl http://127.0.0.1:8000/api/health`; phản hồi `ok: true` cùng `model_available: true` cho biết backend đang hoạt động và tệp mô hình đã được nạp thành công. Dừng server bằng tổ hợp `Ctrl+C`. Để kiểm thử hồi quy trước khi sử dụng hoặc phát hành bản mới, chạy `pytest -q` tại thư mục gốc dự án.

## 6 Kết luận

### 6.1 Tóm tắt kết quả

Đồ án đã xây dựng hệ thống học máy dự đoán và phân tích giá niêm yết laptop từ dữ liệu Chợ Tốt và Websosanh, tương ứng chủ yếu với thị trường laptop đã qua sử dụng và laptop mới. Dữ liệu được làm sạch, chuẩn hóa và hợp nhất để phục vụ phân tích, nhưng kết quả không được xem là thước đo giá trị thị trường chung cho toàn bộ laptop tại Việt Nam.

Sau quá trình xử lý và trích xuất các thông tin cấu hình như thương hiệu, CPU, GPU, RAM, lưu trữ, màn hình, tình trạng và bảo hành, tập mô hình hóa gồm 7.296 mẫu với 86 đặc trưng. Nhiều mô hình hồi quy đã được thử nghiệm; CatBoost sau tinh chỉnh được lựa chọn với RMSE CV trung bình khoảng 5,226 triệu VND. Trên tập holdout, mô hình đạt RMSE 5,913 triệu VND và  $R^2$  xấp xỉ 0,85. Đây là các metric nội bộ của pipeline hiện tại và được dùng làm tham chiếu trước khi mô hình ứng dụng được huấn luyện lại trên toàn bộ dữ liệu.



Nhóm cũng xây dựng ứng dụng web *Laptop Price Studio* chạy local, hỗ trợ nhập cấu hình hoặc mô tả tự nhiên, dự đoán giá và khoảng giá tham khảo, so sánh tin rao, đồng thời khảo sát sự thay đổi dự đoán theo RAM và dung lượng lưu trữ. Các kết quả này chỉ mang tính hỗ trợ phân tích, không được diễn giải như quan hệ nhân quả hoặc kết luận chắc chắn về mức độ đáng mua. Qua đó, đồ án đã hoàn thành quy trình từ thu thập dữ liệu, xây dựng mô hình đến triển khai sản phẩm minh họa.

## 6.2 Hạn chế

Hạn chế rõ nhất của mô hình là sai số tăng mạnh ở phân khúc giá cao. Biểu đồ residual cho thấy phương sai sai số tăng theo mức giá, tức hiện tượng phương sai không đồng nhất. Mô hình có xu hướng dự đoán cao hơn thực tế đối với các sản phẩm giá thấp và dự đoán thấp hơn thực tế đối với các sản phẩm cao cấp. Mẫu này nhất quán với giả thuyết co về vùng giá phổ biến, nhưng cũng có thể phát sinh từ việc thiếu đại diện và thiếu đặc trưng ở phân khúc cao; thí nghiệm hiện tại chưa phân biệt được các cơ chế này.

Một nguyên nhân quan trọng là quy mô dữ liệu còn hạn chế, đặc biệt ở các nhóm laptop cao cấp, workstation và gaming. Sau các bước làm sạch và lọc, tập mô hình hóa gồm 7.296 mẫu; trong đánh giá holdout, chỉ 5.836 mẫu được dùng để huấn luyện, còn artifact ứng dụng được fit lại trên cả 7.296 mẫu. Các tập này chưa bao phủ đầy đủ sự đa dạng của thương hiệu, dòng máy, thế hệ linh kiện, tình trạng sản phẩm và các phân khúc giá trên thị trường.

Các đặc trưng có ảnh hưởng mạnh như CPU và GPU cũng chưa được khai thác triệt để. Dữ liệu từ các nguồn web thường thiếu tên linh kiện đầy đủ, không thống nhất cách mô tả hoặc chỉ cung cấp thông tin ở mức tổng quát. Một số dòng CPU/GPU xuất hiện quá ít nên mô hình khó học được xu hướng giá đáng tin cậy. Vì vậy, những khác biệt quan trọng như thế hệ CPU, hậu tố dòng chip, hiệu năng GPU, công suất thiết kế hoặc phân khúc linh kiện chưa được phản ánh đầy đủ.

Việc tinh chỉnh siêu tham số không tạo ra cải thiện holdout nhất quán trong lần chia hiện tại: RMSE của LightGBM tăng từ 5,785 lên 5,842 và của CatBoost tăng từ 5,819 lên 5,913 triệu VND sau tinh chỉnh. CatBoost tuned vẫn được giữ vì được chọn trước theo RMSE CV thấp nhất; chênh lệch holdout với LightGBM baseline là 2,21%. Quyết định này bảo toàn quy tắc lựa chọn đã định, nhưng báo cáo không tuyên bố CatBoost vượt trội tuyệt đối.

Ngoài ra, giá laptop có thể thay đổi nhanh theo thời gian. Sự xuất hiện của thế hệ CPU/GPU mới, thay đổi nguồn cung, chương trình khuyến mãi, tỷ giá, chi phí nhập khẩu và các biến động kinh tế có thể làm mất bằng giá thực tế khác đáng kể so với thời điểm thu thập dữ liệu. Do đó, mô hình có nguy cơ suy giảm hiệu năng khi được sử dụng lâu dài nếu dữ liệu không được cập nhật thường xuyên.

Phép chia ngẫu nhiên có phân tầng theo giá chỉ ước lượng khả năng dự đoán các

quan sát cùng bối cảnh thu thập; nó chưa kiểm tra khả năng tổng quát sang thời điểm tương lai. Khi có timestamp đáng tin cậy, cần bổ sung phép chia theo thời gian hoặc theo đợt thu thập.

Khoảng giá tham khảo của ứng dụng hiện được xây dựng từ RMSE theo phân khúc và mức độ thiếu thông tin. Phân khúc sai số trong phân tích được tạo theo giá thực tế, còn ứng dụng phải chọn phân khúc theo giá dự đoán; vì vậy một mẫu cao cấp bị dự đoán thấp có thể nhận biên sai số của phân khúc thấp hơn. Đây là quy tắc thực nghiệm chưa được đánh giá coverage, không phải khoảng dự đoán được hiệu chỉnh với bảo đảm xác suất. Ứng dụng cũng chưa quan sát đầy đủ các yếu tố như tình trạng pin, ngoại hình, chất lượng hoàn thiện, phụ kiện, chính sách bảo hành và uy tín người bán. Vì vậy, kết quả chỉ nên được xem là thông tin hỗ trợ, không phải kết luận tuyệt đối về giá trị hoặc mức độ đáng mua của sản phẩm.

Dữ liệu hợp nhất hai cơ chế giá khác nhau. Mô hình sử dụng `condition_score` để biểu diễn máy đã sửa chữa, đã sử dụng và máy mới khi thông tin này có sẵn. Riêng Websosanh không có trường tình trạng và được mã hóa ở mức trung tính 2; đây là giới hạn dữ liệu được chấp nhận trong phạm vi mô hình hợp nhất hiện tại.

Huấn luyện lại trên toàn bộ dữ liệu sau khi cố định pipeline và siêu tham số là bước triển khai được chọn cho đề án. Mô hình trong ứng dụng được fit trên toàn bộ 7.296 mẫu, nên không có metric test riêng cho chính artifact này. Các metric CV và holdout ở Chương 3–4 được dùng làm tham chiếu cho cấu hình CatBoost tuned trước khi retrain; chúng không phải phép đo trực tiếp artifact cuối.

## 6.3 Hướng phát triển

Trong tương lai, hướng cải thiện quan trọng nhất là mở rộng và cập nhật dữ liệu. Dữ liệu nên được thu thập định kỳ từ nhiều cửa hàng, sàn thương mại điện tử và thị trường máy đã qua sử dụng để tăng độ phủ và giảm ảnh hưởng của biến động theo thời gian. Các bản ghi cũng nên lưu thời điểm thu thập để mô hình có thể học xu hướng thay đổi giá.

Nhóm có thể xây dựng bộ từ điển linh kiện chi tiết hơn cho CPU và GPU, bao gồm hãng, dòng, thế hệ, hậu tố, phân khúc hiệu năng và thời điểm ra mắt. Các nguồn tham chiếu về benchmark hoặc thông số kỹ thuật có thể được dùng để tạo thêm đặc trưng định lượng, giúp mô hình hiểu quan hệ giữa hiệu năng phần cứng và giá thay vì chỉ học từ tên danh mục.

Đối với các cấu hình xuất hiện nhiều lần, pipeline hiện tại giữ nguyên quy tắc loại 2.514/10.080 quan sát theo cờ Websosanh để bảo đảm khả năng tái lập các kết quả đã báo cáo. Cờ này không tách hoàn toàn các nhóm theo `merged_spec_key`; đây là giới hạn được chấp nhận trong phạm vi đề án thay vì mở rộng sang một quy trình group split mới.

Trong phạm vi hiện tại, nhóm giữ schema, cách gom nhóm hiếm và cách chia CV

để tránh mở rộng thí nghiệm. Khi dự đoán, `condition_score` tiếp tục là biến chính mô tả tình trạng mới, đã sử dụng hoặc đã sửa chữa; giá trị thiếu/không nhận diện được mã hóa ở mức trung tính 2, nhất quán giữa notebook huấn luyện và encoder ứng dụng.

Để xử lý phương sai không đồng nhất, nhóm có thể thử các hàm mất mát bền vững hơn như Huber loss, Quantile loss hoặc huấn luyện riêng theo từng phân khúc giá. Các phương pháp quantile regression hoặc conformal prediction cũng có thể được nghiên cứu để tạo khoảng giá có cơ sở thống kê tốt hơn.

Về triển khai, hệ thống có thể được bổ sung cơ chế thu thập dữ liệu mới, huấn luyện lại theo lịch và theo dõi sai số sau triển khai. Khi mặt bằng giá thay đổi vượt một ngưỡng nhất định, hệ thống có thể cảnh báo dữ liệu hoặc mô hình đã lỗi thời và cần cập nhật. Nếu triển khai công khai, backend cũng cần được chuyển sang hạ tầng phù hợp hơn, bổ sung HTTPS, giới hạn truy cập, giám sát, ghi log và cơ chế bảo vệ khóa API.

Tóm lại, đề án cho thấy pipeline học máy end-to-end có thể được xây dựng và chạy để dự đoán giá niêm yết tham chiếu trong mẫu dữ liệu hợp nhất. Các giới hạn đã nêu được giữ minh bạch nhưng không làm thay đổi phạm vi thực nghiệm đã chốt của đề án.

## Tài liệu tham khảo

- [1] L. Breiman, ?Random Forests,? *Machine Learning*, **jourvol** 45, **number** 1, **pages** 5–32, 2001. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)
- [2] G. Ke **and others**, ?LightGBM: A Highly Efficient Gradient Boosting Decision Tree,? *in* *Advances in Neural Information Processing Systems* **volume** 30, 2017, **pages** 3146–3154.
- [3] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush **and** A. Gulin, ?CatBoost: Unbiased Boosting with Categorical Features,? *in* *Advances in Neural Information Processing Systems* **volume** 31, 2018, **pages** 6638–6648.
- [4] F. Pedregosa **and others**, ?Scikit-learn: Machine Learning in Python,? *Journal of Machine Learning Research*, **jourvol** 12, **pages** 2825–2830, 2011.

## A Phụ lục

### A.1 Phân công công việc

Bảng 13 trình bày phân công công việc của các thành viên trong nhóm.

Bảng 13: Phân công công việc trong nhóm

| MSSV     | Họ và tên        | Nhiệm vụ                                 |
|----------|------------------|------------------------------------------|
| 23120245 | Nguyễn Quang Duy | Huấn luyện mô hình và phân tích kết quả. |
| 23120258 | Lưu Trọng Hiếu   | Tiền xử lý dữ liệu.                      |
| 23120260 | Văn Đình Hiếu    | Thu thập dữ liệu; xây dựng ứng dụng web. |

### A.2 Cấu trúc và tổ chức thư mục dự án

Dự án được tổ chức theo nguyên tắc tách biệt dữ liệu, mã nguồn xử lý, mô hình đã huấn luyện, ứng dụng web và tài liệu báo cáo. Cấu trúc ở mức chính được trình bày dưới đây; các tệp sinh tự động như `__pycache__` không được liệt kê.

Listing 4: Cấu trúc thư mục chính của dự án.

```

1 Laptop-Price-Prediction/
2 |-- app/
3 |   |-- backend/      # HTTP API, dịch vụ du đoan, cau hinh moi truong
4 |   |-- frontend/     # HTML, CSS, JavaScript va bieu do
5 |-- artifacts/        # Metrics, du đoan, bieu do va model thu nghiem
6 |-- config/           # Cau hinh thu thap du lieu
7 |-- data/
8 |   |-- raw/          # Du lieu goc
9 |   |-- intern/       # Du lieu lam sach va trung gian
10 |  |-- processed/     # Du lieu dung cho mo hinh hoa
11 |-- docs/            # Bao cao du lieu, EDA va cau hinh dac trung
12 |-- models/          # Mo hinh trien khai va schema dac trung
13 |-- pipeline/        # Pipeline thu thap va lam sach
14 |-- reports/
15 |   |-- sections/    # Cac phan LaTeX
16 |   |-- tables/      # Bang dung trong bao cao
17 |   |-- figures/     # Bieu do, anh giao dien va so do
18 |-- scripts/         # Script thuc thi pipeline
19 |-- src/

```

```
20 | |-- clean/          # Quy tắc làm sạch theo nguồn
21 | |-- data/           # Thanh phần thu thập dữ liệu
22 | |-- encoder/        # Parser CPU/GPU và bộ mã hóa
23 | |-- features/       # Xây dựng đặc trưng
24 | |-- models/         # Huấn luyện và thử nghiệm
25 | |-- prediction/     # Khoảng giá và so sánh cấu hình
26 |-- tests/           # Kiểm thử encoder, model và API
27 |-- requirements.txt
28 |-- README.md
```

Trong luồng triển khai, frontend trong `app/frontend` gửi yêu cầu đến backend trong `app/backend`. Backend sử dụng các module từ `src/encoder` và `src/prediction` để chuẩn hóa đầu vào, tạo đặc trưng và xây dựng kết quả trả về. Các tệp trong `models` là artifact cần thiết khi chạy ứng dụng, gồm mô hình CatBoost đã huấn luyện lại trên toàn bộ dữ liệu, schema 86 đặc trưng và cấu hình khoảng giá tham khảo. Ngược lại, `data`, `artifacts` và `docs` chủ yếu phục vụ khả năng tái lập quy trình thu thập, làm sạch, huấn luyện và đánh giá.

Sự phân tách này giúp thay đổi giao diện mà không tác động đến mô hình, thay mô hình mà vẫn giữ hợp đồng đầu vào/đầu ra của API, và truy vết được nguồn gốc của các kết quả báo cáo. Tệp `app/backend/.env` chứa khóa Gemini API, nếu được tạo, chỉ dùng tại máy local và không được đưa vào hệ thống quản lý mã nguồn.